

一、数据集总体情况


数据集共 7 张数据表 + 1 份字段释义文件，覆盖申请主数据、外部征信、历史申请、账户月度明细、还款流水等零售信贷全链路信息。

表名	记录数	字段数	说明
application_train.csv	307,511	122	信贷申请主表（含违约标签 TARGET），本项目的建模样本
application_test.csv	48,744	121	申请主表（无标签），供预测使用
bureau.csv	1,716,428	17	外部机构征信信息
bureau_balance.csv	27,299,925	3	征信账户月度结余明细
previous_application.csv	1,670,214	37	历史信贷记录
POS_CASH_balance.csv	10,001,358	8	消费/现金贷账户月度状态
credit_card_balance.csv	3,840,312	23	信用卡账户月度明细
installments_payments.csv	13,605,401	8	分期还款逐期流水

合计记录数约 5,800 万行，因此附表一律采用分块读取方式统计。

二、数据关联逻辑（主键关系）

各表以申请标识 `SK_ID_CURR` 为核心串联，具体关联关系如下：



规则：

1. `bureau_balance` 没有 `SK_ID_CURR`，必须通过 `bureau` 表的 `SK_ID_BUREAU` 关联到申请，这是附表整合最容易出错的地方。
2. `POS_CASH` / `credit_card` / `installments` 三张表以 `SK_ID_PREV`（历史合同）+ `SK_ID_CURR` 双键关联，聚合到申请粒度时需要先按合同、再按客户聚合，避免行数膨胀。
3. 所有附表对主表都是“一对多”，阶段二做聚合特征时必须按申请 ID 聚合（求和/均值/最大等），保证最后回到一行一申请。

2.1 宽表构建结果

以主表为核心、以上述关联规则完成全表关联整合，输出 `master_table.csv`：

- **维度：**307,511 行×174 列（主表 122 列 + 附表聚合特征 52 列）
- **聚合方式：**每张附表先按 SK_ID_CURR（bureau_balance 先经 SK_ID_BUREAU 映射）做基础聚合（count/sum/mean/max/min），再 left join 回主表；附表一律分块读取，聚合完即释放，不占用常驻内存

各表聚合口径：

附表	聚合特征（示例）
bureau	征信账户数、各状态（活跃/结清/出售/坏账）计数、授信/负债/逾期合计与均值、最大逾期天数、存续期账户数
bureau_balance	月记录数、逾期月数、无欠款月数、逾期月占比、最近账龄
previous_application	历史申请次数、通过/拒绝/取消数、通过率、申请金额合计与均值、申请后放款动作数
POS_CASH_balance	账户月数、最大/平均逾期天数、逾期月数及占比
credit_card_balance	账户月数、余额均值/最大、额度均值、额度使用率均值、最大逾期天数、逾期月占比
installments_payments	还款记录数、逾期还款次数及占比、平均延迟天数、实还总额、应还均值

宽表已保存至 stage1/output/master_table.csv（约 228 MB），是阶段二特征工程（业务衍生特征、WOE 分箱）的直接输入。

三、数据质量巡检结果

3.1 缺失率三级分级总览

按任务书口径（<10%低、10%-30%中、>30%高）逐字段统计，各表分布如下：

表名	字段数	低 (<10%)	中 (10%-30%)	高 (>30%)
application_train.csv	122	65	7	50
bureau.csv	17	12	1	4
bureau_balance.csv	3	3	0	0
previous_application.csv	37	23	3	11
POS_CASH_balance.csv	8	8	0	0
credit_card_balance.csv	23	16	7	0
installments_payments.csv	8	8	0	0

3.2 主表高缺失字段（缺失率最高的 20 个）

主表 50 个高缺失字段中，前 20 个缺失率均超过 59%，且高度集中在房产与居住环境类字段以及 OWN_CAR_AGE（65.99%）、FONDKAPREMONT_MODE（68.39%）。

初步判断：房产类字段中只有拥有房产/居住小区配套数据的客户才有这些信息，对无房产客户天然缺失，并非数据录入问题。这类字段的处理思路是保留“是否缺失”标识特征，缺失本身可能带有业务含义（例如无房产客群的风险画像）。

3.3 附表高缺失字段

- bureau.csv（4 个高缺失）：AMT_ANNUITY（71.47%，部分征信账户无月供信息）、AMT_CREDIT_MAX_OVERDUE（65.51%，无逾期记录则缺失）、DAYS_ENDDATE_FACT（36.92%）、AMT_CREDIT_SUM_LIMIT（34.48%）。除 AMT_ANNUITY 外均为“无逾期/无额度”带来的自然缺失。
- previous_application.csv（11 个高缺失）：RATE_INTEREST_PRIMARY / RATE_INTEREST_PRIVILEGED（99.64%，利率信息几乎全部缺失，应直接剔除或仅做缺失标识）、AMT_DOWN_PAYMENT 与 RATE_DOWN_PAYMENT（53.64%，与产品类型相关）、NAME_TYPE_SUITE（49.12%）、以及 DAYS_FIRST_DRAWING 等放款时序字段（40.30%，未放款的历史申请无此信息）。

3.4 主表中缺失字段

- EXT_SOURCE_3（19.83%，外部信用评分缺失）
- AMT_REQ_CREDIT_BUREAU_HOUR/DAY/WEEK/MON/QRT/YEAR（均 13.50%，征信查询次数缺失）

这两类属于外部数据源覆盖不全导致的缺失，可用中位数填充或加缺失标识。

四、异常值识别与标注

对核心字段按统计原则与业务常识核查，结果如下：

字段	异常情形	样本数	占比	标注
DAYS_EMPLOYED	取值 365243	55,374	18.01%	特殊业务编码：表示失业/无业，非录入错误，不能盖帽或填充，阶段二须单独编码
AMT_INCOME_TOTAL	=0 或 <5,000	0	0%	无异常
AMT_INCOME_TOTAL	>1,000,000	250	0.08%	极端高收入，倾向极端真实样本（P99.9 为 90 万），保留并观察
DAYS_BIRTH	<18 或 >80	0	0%	无异常（P1=22 岁，P99=66 岁）
AMT_ANNUITY	比值 > 1（收入不足覆盖还款）	33	0.01%	疑似录入错误；这 33 例中 5 例违约（违约率 15.15%，高于整体 8.07%），阶段二结合业务规则处理并观察
AMT_CREDIT	>1.5×AMT_GOODS_PRICE	2,564	0.83%	贷款额远超商品价，需复核，倾向保留
CNT_CHILDREN	>5	42	0.01%	最大 19，疑似录入错误

五、字段字典说明

基于字段释义文件的四维业务分类， 输出 field_dictionary.csv:

业务分类	字段数	典型字段
人口属性	78	性别、年龄、婚姻、教育、收入、职业、住房、房产与居住环境（AVG/MODE/MEDI 系列）
交易行为	64	贷款类型、申请渠道与时间、联系方式、材料提交 flag、历史申请行为（previous_application 全部）
还款行为	46	贷款金额、年金、商品价格、社交圈逾期、POS/信用卡/分期还款流水字段
信用历史	29	EXT_SOURCE 外部评分、征信查询次数、bureau 与 bureau_balance 全部字段