

# EDA 探索性数据分析报告

## 一、样本总体情况

主表共 307,511 笔信贷申请，其中违约样本（TARGET=1）24,805 笔，总体违约率 8.07%。正负样本比例约 11.4:1，说明样本不均衡，后续建模需处理（比如类别权重、阈值优化等）。

## 二、单变量分布分析

### 2.1 数值型核心字段

- 年收入（AMT\_INCOME\_TOTAL）：分布右偏，中位数约 14.7 万元，P99.9 约 90 万元，存在少量高收入长尾；收入与违约的相关性极弱（相关系数-0.004），收入高低本身不是强风险因子，需要结合负债一起看。
- 贷款金额（AMT\_CREDIT）与 商品价格（AMT\_GOODS\_PRICE）：均右偏，贷款金额与违约呈弱负相关，金额越大违约率略低，可能与高金额客群资质更优有关。
- 年龄（DAYS\_BIRTH 转正后）：客群以 25-50 岁为主；违约率随年龄增大单调下降。
- 外部信用评分（EXT\_SOURCE\_1/2/3）：整体右偏分布，是全字段中与违约相关性最强的变量（相关系数-0.16~-0.18），评分越高违约率越低，是后续建模的核心特征。

### 2.2 类别型核心字段

- 贷款类型：现金贷（Cash loans）占绝大多数（约 91%），循环贷（Revolving loans）占比小。
- 性别：女性约 65%、男性约 34%，另有 4 例性别未知（XNA）。
- 教育水平：Secondary/secondary special（高中及中专）占 71%，Higher education（高等教育）占 24%，学术学位（Academic degree）仅占 0.05%。
- 收入类型：工薪（Working）51.6%、退休（Pensioner）18%、商业合作（Commercial associate）23.3%、公务员（State servant）7.1%。

### 三、违约相关性分析（分组违约率）

#### 3.1 性别

| 性别 | 样本数     | 违约率    |
|----|---------|--------|
| 女  | 202,448 | 7.00%  |
| 男  | 105,059 | 10.14% |
| 未知 | 4       | 0%     |

男性客群违约率比女性高约 3.1 个百分点，是最显著的差异之一。

#### 3.2 教育水平

| 教育水平                                 | 样本数     | 违约率    |
|--------------------------------------|---------|--------|
| Lower secondary（初中及以下）               | 3,816   | 10.93% |
| Secondary / secondary special（高中/中专） | 218,391 | 8.94%  |
| Incomplete higher（高等教育肄业）            | 10,277  | 8.48%  |
| Higher education（高等教育）               | 74,863  | 5.36%  |
| Academic degree（学术学位）                | 164     | 1.83%  |

违约率随学历提升单调下降，学历是稳定单调的风险排序变量，适合作为 WOE 分箱核心变量。

#### 3.3 收入类型

| 收入类型                        | 样本数     | 违约率      |
|-----------------------------|---------|----------|
| 产假（Maternity leave）         | 5       | 40.00%   |
| 失业（Unemployed）              | 22      | 36.36%   |
| 工薪（Working）                 | 158,774 | 9.59%    |
| 商业合作（Commercial associate）  | 71,617  | 7.48%    |
| 公务员（State servant）          | 21,703  | 5.75%    |
| 退休（Pensioner）               | 55,362  | 5.39%    |
| 商人（Businessman）/学生（Student） | 28      | 0%（样本极少） |

产假、失业两组样本量极小（<25），违约率高但统计不稳健，不能直接当作强规则；稳定职业（公务员、退休）违约率明显低于工薪族。

### 3.4 年龄分箱

| 年龄段   | 样本数    | 违约率    |
|-------|--------|--------|
| 18-25 | 16,318 | 11.74% |
| 25-30 | 36,488 | 11.24% |
| 30-35 | 39,437 | 9.98%  |
| 35-40 | 43,680 | 8.67%  |
| 40-45 | 39,997 | 7.77%  |
| 45-50 | 34,404 | 7.30%  |
| 50-55 | 35,097 | 6.41%  |
| 55-60 | 32,722 | 5.42%  |
| 60+   | 29,368 | 4.92%  |

违约率随年龄严格单调下降（11.74%→4.92%），年轻客群（<30 岁）违约风险显著高于均值，是明显的风险梯度信号。

### 3.5 逾期社交圈（DEF\_30\_CNT\_SOCIAL\_CIRCLE）

| 近 30 天逾期社交圈人数 | 样本数     | 违约率    |
|---------------|---------|--------|
| 0             | 271,324 | 7.78%  |
| 1             | 28,328  | 10.15% |
| 2             | 5,323   | 11.65% |
| 3             | 1,192   | 12.84% |
| 4+            | 311     | 13.83% |

逾期社交圈人数越多违约率越高（7.78%→13.83%），社交网络逾期是强风险预警信号，适合作为衍生特征。

## 四、交叉维度分析

学历 × 收入类型：高等教育 + 稳定职业（公务员/退休）组合违约率最低；低学历 + 工薪组合违约率显著高于均值。学历与收入类型的风险作用相互叠加而非独立。

收入类型 × 住房类型：自有住房（House apartment / With parents）客群违约率低于租房客群；住房类型对风险的区分在工薪客群内部更明显。

地区信用评级 × 学历：地区评级差（3，最差）+ 低学历的组合违约率最高，两个维度的风险信号同时放大。

收入类型 × 30 天逾期社交圈：任何收入类型下，逾期社交圈人数 >0 都会推高违约率，逾期社交圈信号对公务员/退休等低风险职业同样有效。

逾期社交圈×负债比例（补充，任务书点名组合）：负债比例（年金/收入）>1 仅 33 例但违约率 15.15%（5 例违约，高于整体 8.07%）；与逾期社交圈人数叠加时小样本违约率升至 100%）。负债比例 0.5-1.0 + 社交圈逾期人数多的客群违约率也高于均值，两个维度的风险信号互相放大，负债比例是阶段二“收入负债比”衍生特征的重点。

## 五、相关性分析

核心字段与 TARGET 的相关系数排序：

| 字段                         | 与 TARGET 相关系数 | 方向               |
|----------------------------|---------------|------------------|
| EXT_SOURCE_3               | -0.1789       | 负（评分高→违约低）       |
| EXT_SOURCE_2               | -0.1605       | 负                |
| EXT_SOURCE_1               | -0.1553       | 负                |
| DAYS_BIRTH                 | +0.0782       | 正（年龄轻→违约高，见 3.4） |
| REGION_RATING_CLIENT       | +0.0589       | 正（地区评级差→违约高）     |
| DAYS_ID_PUBLISH            | +0.0515       | 正                |
| DAYS_REGISTRATION          | +0.0420       | 正                |
| DEF_60_CNT_SOCIAL_CIRCLE   | +0.0313       | 正（逾期社交圈→违约高）     |
| DEF_30_CNT_SOCIAL_CIRCLE   | +0.0322       | 正                |
| AMT_REQ_CREDIT_BUREAU_YEAR | +0.0199       | 正（征信查询多→违约高）     |

结论：外部信用评分（EXT\_SOURCE 系列）是区分度最强的特征；人口画像类（年龄、地区评级）次之；金额类字段（收入、贷款额、年金）与违约的线性关系很弱，需要靠非线性模型或衍生比率特征（比如负债收入比）。