

1. 概述

从宽表到可落地的评分卡全链路：

步骤	脚本	产出
特征工程（缺失/异常/衍生/初筛）	01_feature_engineering.py	processed_features.csv、feature_list.csv
WOE 分箱（自动 + 业务人工调整）	02_woe_binning.py	woe_bins.csv、woe_iv_summary.csv、woe_encoding_map.csv
贷前可得性校验（合规红线）	03_loan_availability_check.py	loan_availability_check.csv
逻辑回归评分卡	04_logistic_scorecard.py	logit_coefficients.csv 等 5 份
LightGBM 基线对比 + 过拟合校验	05_lgbm_baseline.py	lgbm_performance.csv、model_comparison.csv
双阈值策略测算	06_threshold_strategy.py	threshold_grid.csv、threshold_strategy.csv

2. 特征工程

输入：阶段一宽表 master_table.csv（307,511 × 174）。

2.1 处理内容

1. **缺失处理**：缺失率 <10%的字段填中位数（数值）/众数（类别）；缺失率 ≥10%的字段保留缺失并新增{字段}_MISSING 0/1 标识（“申请时点无记录”本身是贷前信息）。

2. **异常值处理**：

- DAYS_EMPLOYED = 365243（失业占位符）→ 转为 IS_UNEMPLOYED 0/1 标识；
- DEBT_RATIO 盖帽到上限 1.0（负债比例 >1 属数据异常）；
- CNT_CHILDREN 盖帽到 5；
- 年收入 >100 万保留（真实高净值客群，不能当异常删）。

3. **衍生特征**：DEBT_RATIO（年金/收入）、CREDIT_INCOME_RATIO（贷款/收入）、CREDIT_GOODS_RATIO（贷款/商品价）、AGE_YEARS（年龄转年）、EXT_SOURCE_MEAN（三个外部评分均值）。

4. **初筛**：常量列、相关系数 >0.95 高相关列和 VIF>10 迭代剔除。

2.2 结果

- 输出 `processed_features.csv`: $307,511 \times 267$ （主要包含了缺失标识与衍生特征）。
- `feature_list.csv`: 保留 158 个候选特征（按四大业务维度分类：人口属性/交易行为/还款行为/信用历史），初筛剔除 107 个。

3. WOE 分箱

3.1 分箱规则

- 数值字段：等频分箱（最多 10 箱），取值不足自动合并，缺失单独成箱；
- 类别字段：占比 $<1\%$ 的低频取值合并为“其他”，缺失单独成箱；
- 业务人工调整：
 - AGE_YEARS 按业务边界 [18,25,30,35,40,45,50,60] 分箱（年龄段风控口径）；
 - DEBT_RATIO 按负债承受力边界 [0,0.2,0.35,0.5,0.7,1.0] 分箱；
 - DAYS_EMPLOYED 的 365243 单独成“失业”箱。

优化：业务分箱最初用左闭右开，DEBT_RATIO 被盖帽到恰好 1.0 的行落不进任何区间、被切成缺失。已改为右闭。

3.2 IV 排序（全 158 特征前 5）

排名	特征	业务说明	IV
1	EXT_SOURCE_3	外部信用评分 3	0.3293
2	EXT_SOURCE_2	外部信用评分 2	0.3062
3	EXT_SOURCE_1	外部信用评分 1	0.1508
4	bureau_days_credit_mean	征信历史贷款平均期限	0.1227
5	DAYS_EMPLOYED	工作天数（含失业占位符）	0.1112

IV 排序与阶段一完全吻合，说明外部评分仍是区分度最重要的指标，新增的征信聚合特征（bureau_days_credit_mean）进入前 5，说明附表聚合补上了单变量阶段的不足。

4. 贷前可得性校验

4.1 规则

对全部 158 个候选特征按来源归类：

- 申请信息（客户填写）与外部征信（EXT_SOURCE_、AMT_REQ_CREDIT_BUREAU_、bureau、bb_）：贷前可得；
- 本机构历史（prev_、pos_、cc_、inst_）：申请时点征信可查，贷前可得；
- {字段}_MISSING 标识本身表示“申请时点无记录”，属贷前信息；
- 贷后日期已在阶段一宽表构建时转成计数/标记特征，无原始贷后日期入模。

5. 逻辑回归评分卡

5.1 建模流程

- 1.158 个候选特征按分箱规则映射为 WOE 值；
- 2.共线性处理：WOE 转换后特征间共线结构与原始值不同，先剔除常量列和相关系数 >0.95 的高相关列（剔除 59 个，剩 99 个）；
3. 训练/测试划分（7:3，分层抽样，random_state=42）；
4. 逻辑回归拟合（statsmodels）， $p<0.05$ 迭代剔除不显著特征（再剔除 48 个）；
5. 最终选取了 51 个特征，系数；
- 6.评分刻度：基准分 600 分、基准好坏比 50:1、每 20 分好坏比翻倍（PDO=20）。

5.2 模型性能

指标	训练集	测试集
AUC	0.7603	0.7627
KS	0.3901	0.3971

训练与测试几乎一致，无过拟合。KS ≈ 0.39 处于信贷评分卡可用区间。

6. LightGBM 对比与过拟合校验

选择了同一套特征、同一划分方式，训练 LightGBM 作为对照：

模型	训练 AUC	测试 AUC	训练 KS	测试 KS	训练-测试差距
逻辑回归	0.7603	0.7627	0.3901	0.3971	-0.0024
LightGBM	0.8198	0.7712	0.4815	0.4082	0.0485

1. LightGBM 测试集略优（AUC 0.7712 vs 0.7627），但训练-测试差距 0.0485 贴着 0.05 的过拟合红线，泛化略弱；

2.逻辑回归训练/测试一致、可解释、监管友好；

3.业务选型建议：逻辑回归。LightGBM 提升有限（+0.009），不足以弥补可解释性损失。评分卡落地场景优先满足监管对系数透明的要求。

7.双阈值策略测算

基于测试集评分（92,254 个客户，整体坏账率 8.07%），按分数分位每 5%扫描 18 个阈值，计算通过率与通过客户坏账率，再按两套目标各取一档：

方案	目标口径	阈值	通过率	坏账率	业务含义
低风险优先	坏账率 $\leq 2\%$	≥ 585	30.0%	1.92%	只放优质客户，坏账压到行业不良率水平
高效率优先	通过率 $\geq 75\%$	≥ 549	75.0%	4.34%	覆盖大部分客群，坏账率可控

两套方案给业务留下选择空间：要资产质量选低风险或者选择要规模选高效率。结果见 threshold_grid.csv。