

1.概述

本阶段在上一个阶段的模型基础上进行了模型的调优和对比：

1. 超参数调优：网格搜索，输出调优版本；
2. 样本不均衡处理：对比类别权重/SMOTE/阈值优化三种方案；
3. 多版本模型对比：通过 3 个版本来记录迭代轨迹。

2.参数调优

2.1 方法

参数网格：learning_rate {0.05,0.1}、num_leaves {31,63}、max_depth {-1,8}、n_estimators {200,300}、reg_alpha {0,0.5}，共 16 组；交叉验证，以 AUC 为目标；训练/测试划分与上阶段完全一致（7:3 分层抽样，random_state=42），入模特征同为 51 个。

2.2 最优参数

参数	取值	说明
learning_rate	0.05	更小的学习率可配合更多棵树
num_leaves	31	树复杂度适中
max_depth	8	限制深度防过拟合
n_estimators	300	足够多的迭代次数
reg_alpha	0.5	L1 正则

最优交叉验证 AUC：**0.7701**（16 组×3=48 次训练，结果见 lgbm_tuning_results.csv）。

2.3 三个版本迭代轨迹

版本	训练 AUC	测试 AUC	训练 KS	测试 KS	过拟合差距
v0 基线（默认参数）	0.8198	0.7712	0.4815	0.4082	0.0485
v1 调优（网格搜索）	0.8374	0.7738	0.4901	0.4106	0.0636
v2 调优+样本均衡	0.8352	0.7737	0.4920	0.4133	0.0615

解读：

1. 调优带来小幅提升：测试 AUC 0.7712→0.7738（+0.003），KS 0.4082 →0.4106；

- 2.代价是过拟合差距变大（0.0485→0.0636）：拟合能力更强，训练集记得更深；
- 3.v2 叠加类别权重后测试 AUC 基本持平、KS 继续升到 0.4133，差距降到 0.0615；
- 4.三档版本中 v1 测试 AUC 最优，后续可解释性分析基于 v1 展开。

3.样本不均衡处理

违约样本占比 8.07%，属典型类别不均衡。固定 v1 参数，对比四种方案（测试集）：

方案	分类阈值	精确率	召回率	F1	测试 AUC
A 基线（不处理）	0.50	0.5353	0.0367	0.0686	0.7726
B 类别权重	0.50	0.1826	0.6732	0.2873	0.7720
C SMOTE 过采样	0.50	0.1752	0.3208	0.2266	0.6740
D 阈值优化	0.15	0.2540	0.4444	0.3233	0.7726

3.1 关键发现

- 1.基线召回率几乎为 0（0.037）：默认 0.5 阈值下，违约概率很难超过 0.5，模型“一个都不抓”——这是类别不均衡的典型表现；
- 2.类别权重大幅提升召回率（0.037 →0.673），精确率降到 0.18，F1 0.287；
- 3.SMOTE 反而拖累模型：测试 AUC 从 0.773 掉到 0.674。原因可能是合成样本在树模型上引入噪声分布，且只对训练集过采样、测试分布不变，收益为负。SMOTE 对 LightGBM 此类场景不；
- 4.阈值优化性价比最高：不重训、只把阈值降到 0.15，召回率 0.44、F1 最高 0.323，AUC 不变。缺点是精确率偏低（0.25），放行的违约多。

3.2 选择建议

如果目标是追求抓全违约（高召回并配合人工复核）：选类别权重（召回 0.67）；
 如果目标是追求平衡（F1 最高、实现最简单）：选阈值优化（0.15 阈值）；
 不建议 SMOTE，因为模型能力下降，除非换算法再做评估。