模型可解释性分析报告（LightGBM v1 调优模型）

1. 概述

对 LightGBM v1 调优模型（51 个入模特征）做三层解释：

1. 全局可解释性：通过特征重要性、SHAP 均值重要性和全局摘要图，识别前十核心因子；

2. 局部可解释性：高/低风险典型样本各 3 个的 SHAP 力导图；

3. 合规性校验：性别、地域评级分群预测差异检查，确保符合公平信贷原则。

2. 全局可解释性

2.1 核心因子排序（SHAP 均值重要性 Top10，附阶段一 IV 对照）

排名	特征	SHAP 均值	阶段一 IV	业务含义
1	EXT_SOURCE_2	0.3176	0.3066	外部征信评分 2
2	EXT_SOURCE_3	0.2953	0.3294	外部征信评分 3
3	EXT_SOURCE_1	0.1741	0.1509	外部征信评分 1
4	inst_overdue_ratio	0.1614	—	分期还款逾期占比
5	CREDIT_GOODS_RATIO	0.1274	—	贷款金额/商品价值比
6	CODE_GENDER	0.1135	—	性别
7	NAME_EDUCATION_TYPE	0.0897	0.0508	教育水平
8	DAYS_BIRTH	0.0881	0.0842	年龄
9	DAYS_EMPLOYED	0.0868	0.1012	工作天数
10	OWN_CAR_AGE	0.0829	—	车龄

注：IV 列为横线（—）表示阶段一 IV 表未覆盖的衍生或类别字段。

三个外部征信评分（EXT_SOURCE_1/2/3）的 SHAP 均值排名前三，与阶段一单变量 IV 排序（EXT_SOURCE_3/2/1 前三）一致；模型 Gain 重要性同样由三者占据前三（EXT_SOURCE_1/3/2）。三类证据互相印证，核心驱动因子结论与 IV 分析及行业常识对齐。

3. 局部可解释性

从 SHAP 抽样子集（2000 行）中选取：

1. 高风险样本 3 个：TARGET=1 且预测违约概率最高的客户（产出中的 shap_force_high_risk_1~3.png）；

2. 低风险样本 3 个：TARGET=0 且预测概率最低的客户（产出中的 shap_force_low_risk_1~3.png）。

图片展示了单个客户的评分构成：即不同特征驱动的违约方向和安全方向。图内红色为推高违约概率的因素、蓝色为压低因素，可直接用于审核对客户的解释。

4. 合规性校验

4.1 性别分群

性别编码	样本数	实际违约率	平均预测违约概率
0	60,826	7.01%	7.05%
1	31,426	10.14%	9.95%
2	2	0.00%	11.86%

4.2 地域评级分群

地域评级	样本数	实际违约率	平均预测违约概率
1（最优）	9,646	5.00%	4.98%
2	68,138	7.82%	7.87%
3（最差）	14,470	11.33%	10.88%

4.3 结论

1. 模型没有放大群体差异：模型给男性群体预测的平均违约概率是 9.95%，而男性实际违约率是 10.14%；给女性预测 7.05%，实际 7.01%，预测和现实几乎一致（差不到 0.5%）；

2. 差异来源是数据本身：男性实际违约率 10.14% 高于女性 7.01%，劣质地区实际 11.33% 高于优质地区 5.00%，说明模型如实反映了数据里的真实规律，并非对性别、地域的额外加权；

3. 公平信贷结论：模型在性别、地域上无额外偏差，差异属风险相关且可解释；如监管要求更严，可在风控策略层面对敏感维度单独约束（属业务决策，非模型问题）。

5. 业务化风险因子总结

结合 SHAP 与 IV 两类证据，核心风险驱动因素：

1. 外部信用评分（EXT_SOURCE_1/2/3）：SHAP 与 IV 双证据下最强的驱动因子，第三方征信评分高低直接决定违约风险；

2. 历史逾期与负债结构（inst_overdue_ratio、CREDIT_GOODS_RATIO）：分期还款逾期占比高、贷款金额相对商品价值过高是重要预警信号；

3. 客户基础画像（CODE_GENDER、NAME_EDUCATION_TYPE、DAYS_BIRTH）：性别、低学历、年轻客群违约偏高；

4. 工作与收入稳定性（DAYS_EMPLOYED、OWN_CAR_AGE、AMT_ANNUITY）：失业/短期雇佣、车龄信息与还款能力相关。