个人消费信贷智能风险评分模型构建与策略优化

项目技术文档

1. 项目背景与目标 2

1.1 业务背景 2

1.2 项目目标与范围 2

2. 数据说明与处理逻辑 3

2.1 数据来源与表结构 3

2.2 关联逻辑与宽表构建 4

2.3 数据质量校验 4

2.4 字段字典 4

3. 特征工程方案 5

3.1 数据预处理 5

3.2 特征衍生与初筛 5

3.3 WOE 分箱与 IV 排序 5

3.4 贷前可得性校验 6

3.5 特征筛选与共线性检验 6

4. 模型设计与迭代过程 6

4.1 基线模型：逻辑回归评分卡 6

4.2 对比模型：LightGBM 6

4.3 参数调优与多版本迭代 6

4.4 样本不均衡处理 7

4.5 模型可解释性分析 7

4.6 模型选型结论 8

5. 风险策略方案 9

5.1 三档风险分层体系 9

5.2 两套阈值方案 9

5.3 策略效果模拟与行业参考基线 9

5.4 人工审核核查项建议 10

5.5 局限与落地注意事项 11
6. 方案价值评估 11
6.1 测算假设 11
6.2 价值测算结果 11
6.3 落地可行性分析 12
7. 代码使用说明 12
7.1 项目目录结构 12
7.2 运行方式 12
7.3 依赖环境 12
7.4 代码规范 13
8. 问题记录 13
8.1 数据处理问题 12
8.2 特征建模问题 13

1.项目背景与目标

1.1 业务背景

随着零售信贷业务在全球范围内加速数字化，线上个人分期贷款申请量持续走高。行业调研显示，2026 年二季度国内住户贷款总余额约 82.91 亿元，剔除住房贷款后的纯消费信贷余额达 20.82 万亿元。行业已经告别高速粗放扩张阶段，步入平稳调整期，风控压力随之加大。过去贷前风控大多依靠规则引擎，这套模式如今短板愈发突出：规则模型很难捕捉复杂的非线性风险特征，识别精度有限；审批环节人工介入较多，业务效率不高。因此依托数据与算法优化贷前风控能力，也成了零售信贷数字化转型的主流方向。

1.2 项目目标与范围

本项目聚焦网上个人信贷申请的信用风险评估核心场景，以公开信贷数据集为基础，完整覆盖从数据治理、特征构建、模型开发到策略设计的贷前风控全链路，最终

输出可落地的风险分层审批方案原型。项目按四个阶段推进：阶段一为业务调研与数据资产梳理，阶段二为特征工程体系搭建与基线模型构建，阶段三为模型优化与风险分层策略设计，阶段四为方案价值评估与项目成果整合。

2.数据说明与处理逻辑

2.1 数据来源与表结构

项目采用业界通用的真实业务去标识化信贷风控数据集，包含 7 张关联数据表与 1 份字段释义文件，总记录量约 5,800 万行。各表情况如下表所示。

表 1 数据集表结构与规模

表名	记录数	字段数	说明
application_train.csv	307,511	122	信贷申请主表（含违约标签 TARGET）
application_test.csv	48,744	121	申请主表（无标签，供预测）
bureau.csv	1,716,428	17	外部机构征信信息
bureau_balance.csv	27,299,925	3	征信账户月度结余明细
previous_application.csv	1,670,214	37	本机构历史信贷申请
POS_CASH_balance.csv	10,001,358	8	消费/现金贷账户月度状态
credit_card_balance.csv	3,840,312	23	信用卡账户月度明细
installments_payments.csv	13,605,401	8	分期还款逐期流水

2.2 关联逻辑与宽表构建

各表以申请标识 SK_ID_CURR 为核心串联。bureau_balance 没有 SK_ID_CURR，必须通过 bureau 表的 SK_ID_BUREAU 关联到申请，POS_CASH、credit_card、installments 三张表以 SK_ID_PREV 加 SK_ID_CURR 双键关联，聚合到申请粒度时先按合同、再按客户聚合；所有附表对主表均为一对多关系，按申请标识聚合后回到一行一申请。由于附表的记录量较大，一律分块读取、聚合完即释放内存。

宽表构建输出 master_table.csv，维度为 307,511 行×174 列（主表 122 列 + 附表聚合特征 52 列），聚合特征覆盖征信账户数与状态、逾期月数及占比、历史申请次数与通过率、账户额度使用率、还款逾期占比等，作为阶段二特征工程的直接输入。

2.3 数据质量校验

按缺失率三级分级（低于 10%为低、10%-30%为中、高于 30%为高）逐字段巡检，主表 122 个字段中低缺失 65 个、中缺失 7 个、高缺失 50 个；高缺失集中在房产与居住环境类字段（主要来自无房产客户的天然缺失，不是录入的问题）以及 EXT_SOURCE_3（19.83%）等外部数据源覆盖不全字段。

异常值识别结果：DAYS_EMPLOYED 取值为 365243 的 55,374 例（18.01%）为特殊业务编码（失业占位符），不能盖帽或填充，需要单独编码；年收入超过 100 万的 250 例倾向为极端真实样本，保留观察；年金收入比大于 1 的 33 例中 5 例违约（违约率 15.15%，高于整体 8.07%），疑似录入错误，结合业务规则处理；子女数大于 5 的 42 例优先选择盖帽处理。

合规红线方面，执行了时间窗口校验：确认所有聚合特征均取自申请时点之前的可得信息，附表原始贷后日期在宽表构建时已转为计数或标记特征，未混入贷后数据。

2.4 字段字典

基于字段释义文件按四维业务分类输出字段字典（field_dictionary.csv）：人口属性 78 个字段、交易行为 64 个、还款行为 46 个、信用历史 29 个，覆盖全部核心字段的业务释义与取值规则。

3.特征工程方案

3.1 数据预处理

缺失处理按缺失率分级做出方案：首先缺失率低于 10%的数值字段填中位数、类别字段填众数；其次缺失率不低于 10%的字段保留缺失并新增 0/1 标识，而申请时点无记录说明本身是贷前可得信息。异常处理包括有失业占位符转为 IS_UNEMPLOYED 标识；负债比例盖帽至上限 1.0；子女数盖帽至 5；年收入超过 100 万的极端高收入保留。

3.2 特征衍生与初筛

按风控业务常识构造衍生特征：收入负债比（年金/收入）、贷款收入比、贷款商品价比、年龄（转年）、外部评分均值（EXT_SOURCE 三个评分均值）。初筛剔除常量列、相关系数大于 0.95 的高相关列与方差膨胀因子（VIF）大于 10 的冗余列，输出 processed_features.csv（307,511 ×267），候选特征 158 个，按人口属性、交易行为、还款行为、信用历史四大维度分类。

3.3 WOE 分箱与 IV 排序

数值字段采用等频分箱（最多 10 箱）并自动合并小箱、缺失部分采用单独成箱；类别字段低频取值合并为“其他”。在自动分箱基础上按业务逻辑人工调整：年龄按业务边界[18,25,30,35,40,45,50,60]分箱，负债比例按承受力边界[0,0.2,0.35,0.5,0.7,1.0]分箱，失业占位符单独成箱。WOE 分箱采用右闭区间，避免盖帽边界值落入空箱。

表 2 候选特征 IV 排序前 5（共 158 特征）

排名	特征	业务说明	IV
1	EXT_SOURCE_3	外部信用评分 3	0.3293
2	EXT_SOURCE_2	外部信用评分 2	0.3062
3	EXT_SOURCE_1	外部信用评分 1	0.1508
4	bureau_days_credit_mean	征信历史贷款平均期限	0.1227
5	DAYS_EMPLOYED	工作天数（含失业占位符）	0.1112

3.4 贷前可得性校验

对全部候选特征按来源归类校验贷前可得性：申请信息、外部征信（EXT_SOURCE 系列、征信查询次数、bureau、bureau_balance）贷前可得；本机构历史申请与账户聚合字段申请时点征信可查，贷前可得；缺失标识本身表示申请时点无记录，属贷前信息。校验结果确认无贷后数据入模。

3.5 特征筛选与共线性检验

WOE 转换后特征间共线结构与原始值不同，先剔除常量列与相关系数绝对值大于 0.95 的高相关列（剔除 59 个，剩 99 个），再在建模过程中通过显著性检验剔除不显著特征，最终入模特征 51 个，并用 VIF 检验控制共线性。

4.模型设计与迭代过程

4.1 基线模型：逻辑回归评分卡

按银行传统信用评分卡技术标准，采用分层随机抽样按 7:3 划分训练集与测试集（random_state=42），以 51 个特征对应的 WOE 值为输入训练逻辑回归（statsmodels），迭代剔除 p 值不显著的系数。评分刻度采用基准分 600 分、基准好坏比 50:1、每 20 分好坏比翻倍（PDO=20）。测试集性能：AUC 0.7627、KS 0.3971，训练与测试几乎一致（差距-0.0024），无过拟合，KS 处于信贷评分卡可用区间。

4.2 对比模型：LightGBM

采用同一套特征与同一划分方式训练 LightGBM 作为对照：测试 AUC 0.7712、KS 0.4082，略优于逻辑回归，但训练-测试差距 0.0485 接近过拟合红线，泛化能力略弱。从区分能力、训练效率、缺失值容忍度、可解释性四个维度对比，逻辑回归训练测试一致、系数透明、监管友好，作为落地基线。

4.3 调优与多版本迭代

对 LightGBM 采用网格搜索调优（learning_rate、num_leaves、max_depth、n_estimators、reg_alpha，共 16 组 × 3 折交叉验证，以 AUC 为目标），最优参数为学

习率 0.05、叶子数 31、最大深度 8、迭代 300 次、L1 正则系数 0.5，最优交叉验证 AUC 0.7701。

表 3 模型迭代三版本性能

版本	训练 AUC	测试 AUC	训练 KS	测试 KS	过拟合差距
v0 基线（默认参数）	0.8198	0.7712	0.4815	0.4082	0.0485
v1 调优（网格搜索）	0.8374	0.7738	0.4901	0.4106	0.0636
v2 调优+样本均衡	0.8352	0.7737	0.4920	0.4133	0.0615

由表中可知，调优带来了小幅的提升（测试 AUC 从 0.7712 升至 0.7738），代价则是过拟合差距增大；加入类别权重后测试 AUC 基本持平、KS 继续升至 0.4133。三版本中 v1 测试 AUC 最优，后续可解释性分析基于 v1 展开。

4.4 样本不均衡处理

违约样本占比 8.07%，属典型类别不均衡。固定 v1 参数对比四种方案：基线（不处理）召回率仅 0.037，模型几乎一个都不抓；但将类别权重召回率升至 0.673、F1 0.287；SMOTE 过采样反而拖累模型，测试 AUC 从 0.773 降至 0.674，合成样本在树模型上引入噪声、收益为负；阈值优化（0.15）召回率 0.444、F1 最高 0.323，且 AUC 不变。建议：追求抓全违约选类别权重，追求平衡与实现简单选阈值优化，不建议 SMOTE。

4.5 模型可解释性分析

全局可解释性基于 SHAP 均值重要性识别前十核心因子，与阶段一单变量 IV 排序对照。三个外部征信评分 SHAP 均值排名前三，与 IV 排序（EXT_SOURCE_3/2/1 前三）一致，模型 Gain 重要性同样由三者占据前三，三类证据互相印证，核心驱动因子结论与 IV 分析及行业常识对齐。

表 4 SHAP 全局特征重要性 Top10

排名	特征	SHAP 均值	业务含义
1	EXT_SOURCE_2	0.3176	外部征信评分 2
2	EXT_SOURCE_3	0.2953	外部征信评分 3
3	EXT_SOURCE_1	0.1741	外部征信评分 1
4	inst_overdue_ratio	0.1614	分期还款逾期占比
5	CREDIT_GOODS_RATIO	0.1274	贷款金额/商品价值比
6	CODE_GENDER	0.1135	性别
7	NAME_EDUCATION_TYPE	0.0897	教育水平
8	DAYS_BIRTH	0.0881	年龄
9	DAYS_EMPLOYED	0.0868	工作天数
10	OWN_CAR_AGE	0.0829	车龄

局部可解释性选取高风险、低风险典型样本各 3 个输出 SHAP 力导图，展示单客户评分构成。合规性校验按性别、地域评级分群比较实际违约率与平均预测违约概率：男性实际 10.14%对预测 9.95%、女性实际 7.01%对预测 7.05%，差异均小于 0.5%；地域评级最优档实际 5.00%对预测 4.98%、最差档实际 11.33%对预测 10.88%。模型没有放大群体差异，差异来自数据本身的真实规律，符合公平信贷原则。

4.6 模型选型结论

核心风险驱动因素四类：外部信用评分（最强驱动因子）、历史逾期与负债结构、客户基础画像、工作与收入稳定性。本次落地选型最终确定采用逻辑回归评分卡。对比测试发现，LightGBM 在测试集上指标提升幅度仅约 0.009，增益十分有限，不足以抵消模型可解释性下降带来的成本；而评分卡方案能够优先满足监管对模型系数透明度的硬性要求，更适配业务场景。

5.风险策略方案

5.1 三档风险分层体系

按评分卡分数从低到高划分三档：低风险自动通过（分数高于通过线，机器直接放行）、中风险人工审核（通过线与拒绝线之间，转人工复核）、高风险自动拒绝（因为分数低于拒绝线，直接拒绝）。

5.2 两套阈值方案

表 5 两套阈值方案

方案	自动通过线（分位）	自动拒绝线（分位）	思路
稳健方案	60%（仅放行前 40% 高分）	30%	自动化率低、坏账低
进取方案	40%（放行前 60% 高分）	20%	自动化率高、覆盖广

中风险档转人工审核后，假设可拦截一半违约客户（REVIEW_BLOCK_RATE=0.5），该比例为业务假设，实际按审核团队质量与核查规则调整。坏账率计算口径统一为放款客群坏账率：最终坏账率等于自动通过档坏账笔数与中风险档坏账笔数乘以（1 减去拦截率）之和除以最终放款笔数。

5.3 策略效果模拟与行业参考基线

表 6 两套方案三档测算（测试集的 92,254 样本）

指标	稳健方案	进取方案
低风险自动通过占比	39.99%	59.99%
中风险人工审核占比	29.99%	20.00%
高风险自动拒绝占比	30.02%	20.00%
低风险档坏账率	2.28%	3.24%
中风险档坏账率	6.03%	9.53%
高风险档坏账率	17.83%	21.11%
自动审批率	40.0%	60.0%

人工审核占比	30.0%	20.0%
最终通过率	69.98%	80.00%
最终坏账率	2.60%	3.62%

表 7 策略效果与行业参考基线对比

策略	通过率	坏账率	人工审核占比	自动审批率	说明
传统规则引擎基线（行业参考）	85%	4.0%	0%	85%	行业参考基线（主对比基准），模拟值
稳健方案	69.98%	2.60%	30%	40%	模型驱动三档分层策略
进取方案	80.00%	3.62%	20%	60%	模型驱动三档分层策略

对比基线采用传统规则引擎的行业参考水平（通过率 85%、坏账率 4.0%），依据持牌消费金融公司公开不良率约 1.5%至 3.5%的区间并结合本项目客群更次级的特点偏保守设定，已标注为模拟值。以行业参考基线（坏账率 4.0%）为基准，模型分层将坏账率压至 2.6%至 3.6%：稳健方案降幅约 35%、进取方案约 9.5%。代价是客群覆盖：稳健方案拒掉约 30%客户（其中约一半是潜在好客户，可能会发生误判），进取方案拒掉约 20%。要资产质量选稳健、要规模选进取。

5.4 人工审核核查项建议

中风险档客户建议重点核查：收入稳定性（近 6 个月工资流水是否连续、有无大额异常进出）；工作信息真实性（单位信息是否可核验，任职年限与申请信息是否一致）；负债压力（可以按照新增贷款后月供占收入比是否超过一半来量化）；历史逾期解释（近 1 年逾期记录的原因说明与证明材料）；资料一致性（例如申请表、征信报告、流水中的联系方式与住址是否一致）。

5.5 局限与落地注意事项

1.拦截率是假设：REVIEW_BLOCK_RATE=0.5 需在试点中校准，若实际拦截率低于 50%，最终坏账率将上浮；

2.成本没有量化：未计入人工审核人力成本、误拒客户的流失损失，落地前需结合价值评估；

3.阈值可按额度分层：同一客户不同贷款额度可用不同通过线，本方案给出的是单一阈值基准；

4.行业参考基线为模拟值：正式上线前需结合本机构实际规则引擎水平校准；

5.重新验证：当前基于测试集约 9.2 万样本，正式上线前需在全样本加新样本上做时间外验证。

6.方案价值评估

6.1 测算假设

价值测算按 10 万笔申请、平均授信额度 3 万元、坏账损失率 50%（单笔违约平均损失约 1.5 万元）、人工审核单笔 20 分钟、审核人力时薪 50 元测算，对比基线为行业参考基线（坏账率 4.0%）。

6.2 价值测算结果

表 8 两套方案价值测算（相对行业参考基线）

方案	通过笔数	坏账笔数	较基线减少坏账笔数	坏账损失减少（万元）	人工审核笔数	节省人工工时（小时）	人工成本节省（万元）	合计价值（万元）
稳健方案	69,980	1,819	2,181	3,271.5	29,990	23,337	116.7	3,388.2
进取方案	80,000	2,896	1,104	1,656.0	20,000	26,667	133.3	1,789.3

稳健方案合计价值约 3,388 万元（主要以坏账损失减少为目标），进取方案约 1,789 万元；进取方案通过率更高但坏账损失节省更少。若机构当期更缺资产质量，稳健方案价值更高；若更缺放款规模，进取方案更合适。

6.3 落地可行性分析

从四个维度评估：数据基础方面，项目数据为公开去标识化数据集，与银行真实数据存在差异，需以机构自有数据重建宽表与标签；技术架构方面，逻辑回归评分卡与三档分层策略可直接嵌入决策引擎，实施成本低；合规方面，模型通过公平信贷校验、系数透明、可解释，满足监管要求；业务接受度方面，人工审核核查项与现有审批流程衔接顺畅。建议分阶段落地：先以试点客群上线稳健方案并校准拦截率与基线，再逐步扩大覆盖并补充贷后监测。

7.代码使用说明

7.1 项目目录结构

项目按任务书四阶段组织：src/credit_risk 下按阶段划分代码目录（stage1_data_assets、stage2_features、stage3_strategy、stage4_value），output 下按阶段存放 CSV 与图表产物，docs 下存放各阶段报告，另含 pyproject.toml（Black/isort/flake8 配置）、requirements.txt、README.md。

7.2 运行方式

一键复现：安装依赖后运行 python scripts/run_all.py（约 40 至 60 分钟）；也可按阶段逐个运行脚本，输出默认写入项目 output 目录，脚本通过 PROJECT_ROOT 动态定位项目根，不依赖绝对路径。阶段二脚本需按顺序运行（04 依赖 02 的 WOE 映射，05/06 依赖 04 输出），阶段三 03 需要 shap、02 需要 imbalanced-learn。

7.3 依赖环境

Python 3.10 及以上，依赖清单见 requirements.txt，核心包括 pandas、numpy、scikit-learn、statsmodels、lightgbm、shap、imbalanced-learn、matplotlib、seaborn。

7.4 代码规范

遵循项目编码规范：PEP 8 与 Black 格式（行宽 88 字符）、Google 风格 docstring、类型注解、导入分组（标准库/第三方/本地）、src 包结构。提交信息遵循约定式提交

8.问题记录

8.1 数据问题

1.附表规模大：bureau_balance 约 2,730 万行、installments 约 1,360 万行，全量读入内存不足，采用分块读取、聚合完即释放；

2. bureau_balance 无申请标识：需先经 bureau 表的 SK_ID_BUREAU 映射，需要注意；

3.附表一对多导致行数膨胀：先按合同（SK_ID_PREV）再按客户（SK_ID_CURR）聚合，保证回到一行一份申请。

8.2 特征与建模问题

1.分箱边界：业务分箱最初用左闭右开，负债比例被盖帽到恰好 1.0 的行落不进任何区间被切为缺失，改为右闭区间后修复；

2.样本不均衡：SMOTE 在 LightGBM 上测试 AUC 从 0.773 降至 0.674，合成样本引入噪声，最终选择类别权重或阈值优化；

3.过拟合风险：LightGBM 调优后训练-测试差距升至 0.0636，通过限制深度、加 L1 正则与过拟合校验控制；

4.可解释性错误：全局 SHAP 特征重要性初版存在特征名与数值错位，导致外部征信评分未进入前十，修复后 SHAP、Gain、IV 三类证据对齐；

5.合规红线：为避免贷后数据混入，阶段一执行时间窗口校验、阶段二执行贷前可得性校验，双重复核。

参考文献

1. 安泰信用评级：《消费金融行业信用风险分析》（2025）；

2. 艾瑞咨询：《2025 年中国消费金融行业研究报告》；

3. 中国银行业协会：《中国消费金融公司发展报告（2025/2026）》；

4. 花旗集团 2025 年报（Letter to Shareholders）、2026 Investor Day；

5.中国人民银行 2026 年二季度金融统计数据；

6.项目各阶段报告：行业调研简报、数据质量评估与字段字典报告、EDA 报告、特征工程与基线模型报告、模型优化与多版本对比报告、模型可解释性分析报告、风险分层与审批策略方案。